ch1: Markov Decision Process

Static Concepts:
state(S) - policy(pi) - action(A) - model(p) - state(S')
reward(R') from transition
return(G) from trajectory
value(V+Q)

策略与价值:
①reward、return、value，用来评估一个策略的好坏。
策略与价值一一对应。
②价值比较，策略比较，策略改进定理。
③强化学习的终极目标，求取最优策略，
最优策略不唯一，最优价值唯一。
最优动作价值，意味着选取这个动作，未来回报的期望最大。
④r线性变换，V+Q线性变换，改变最优价值，不改变greedy最优策略。
⑤迭代时，最优策略可能已经稳定了，但是对应的最优价值还没稳定。
⑥从终止状态反向迭代更新价值，速度更快。但是哪里是终止状态？上帝视角。

$$p\left(s', r \mid s, a\right) = \Pr\left\{S_t = s', R_t = r \mid S_{t-1} = s, A_{t-1} = a\right\}$$

$$\sum_{s' \in S} \sum_{r \in R} p\left(s', r \mid s, a\right) = 1$$

$$p\left(s' \mid s, a\right) = \sum_{r \in R} p\left(s', r \mid s, a\right)$$

$$r(s, a) = \sum_{s' \in S} \sum_{r \in R} \left(p\left(s', r \mid s, a\right) * r\right)$$

ch2: Bellman Equations

Static Relationship
实质：描述状态值之间的静态关系（单项形式、矩阵形式）
求解：（矩阵求逆、数值迭代）—（policy-evaluation）

$$
\begin{aligned}
v_\pi(s) &= E_\pi\left[G_t \mid S_t = s\right] && (Definition)\\
&= E_\pi\left[R_{t+1} + \gamma G_{t+1} \mid S_t = s\right] && (TD-0)\\
&= E_\pi\left[R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + ... \mid S_t = s\right] && (TD-n)(TD- \bowtie = MC)\\
&= \sum_{a\in A} \pi(a \mid s) \sum_{s',r} p\left(s', r \mid s, a\right) * \left[r + \gamma E_\pi\left[G_{t+1} \mid S_{t+1} = s'\right]\right]\\
&= \sum_{a\in A} \pi(a \mid s) \sum_{s',r} p\left(s', r \mid s, a\right) * \left[r + \gamma v_\pi\left(s'\right)\right] && (BEs)\\
&= \sum_{a\in A} \pi(a \mid s) * q_\pi(s,a)
\end{aligned}
$$

$$
\begin{aligned}
q_\pi(s,a) &= E_\pi\left[G_t \mid S_t = s, A_t = a\right] && (Definition)\\
&= E_\pi\left[R_{t+1} + \gamma G_{t+1} \mid S_t = s, A_t = a\right] && (TD-0)\\
&= E_\pi\left[R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + ... \mid S_t = s, A_t = a\right] && (TD-n)(TD- \bowtie = MC)\\
&= \sum_{s',r} p\left(s', r \mid s, a\right) * \left[r + \gamma E_\pi\left[G_{t+1} \mid S_{t+1} = s'\right]\right]\\
&= \sum_{s',r} p\left(s', r \mid s, a\right) * \left[r + \gamma v_\pi\left(s'\right)\right]\\
&= \sum_{s',r} p\left(s', r \mid s, a\right) * \left[r + \gamma \sum_{a'\in A} \pi!\left(a' \mid s'\right) * q_\pi\left(s', a'\right)\right] && (BEs)
\end{aligned}
$$

policy-comparison:

$$\pi' \geq \pi \quad \longleftrightarrow \quad v_{\pi'}(s) \geq v_{\pi}(s) \qquad \forall s \in S$$

policy-improvement:

$$E_{\pi'}\left[q_{\pi}\left(s, \pi'(s)\right)\right] \geq v_{\pi}(s) = E_{\pi}\left[q_{\pi}\left(s, \pi(s)\right)\right] \qquad \forall s \in S$$

Bellman Optimal Equations:

$$\begin{aligned} v_*(s) &= \max_{\pi} v_{\pi}(s) && (Definition) \\ &= \max_{\pi} \left(r_{\pi} + \gamma P_{\pi} v\right) && (BOEs) \\ &= \max_{a \in A} q_{\pi *}(s, a) \qquad \forall s \in S \end{aligned}$$

Contraction Mapping Theorem (迭代收敛至唯一不动点)
贝尔曼最优方程的收缩迭代过程，即是value iteration算法

ch3: Dynamic Programming

理解:
Model-based. Dynamics with Model p.
①已知模型p，给定策略Pi，解BEs，得到价值V。
两种解法：矩阵求逆、数值迭代。

(1) Policy Iteration:
Policy Evaluation:

$$v_{\pi_k} = r_{\pi_k} + \gamma P_{\pi_k} v_{\pi_k}$$

Policy Improvement:

$$\pi_{k+1} = \arg\max_{\pi}(r_\pi + \gamma P_\pi v_k)$$

(2) Value Iteration:

$$v_{k+1} = \max_{\pi}(r_\pi + \gamma P_\pi v_k)$$

Policy Update:

$$\pi_{k+1} = \arg\max_{\pi}(r_\pi + \gamma P_\pi v_k)$$

Value Update:

$$v_{k+1} = r_{\pi+1} + \gamma P_{\pi+1} v_k$$

(3) Turncated Iteration:
值迭代有限次数（介于1次与无穷次之间）；值也未稳定，就进行策略改进

ch4: Monte Carlo

Sample:

$$v_\pi(s) = E_\pi\left[G_t = R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + ... \mid S_t = s\right] \qquad (TD- \bowtie = MC)$$

$$q_\pi(s,a) = E_\pi\left[G_t = R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + ... \mid S_t = s, A_t = a\right] \qquad (TD- \bowtie = MC)$$

理解:
Model-free. Dynamics with Trajectory.
①采样进行估计，依据概率论的大数定理。
②episode长度（探索半径是否覆盖终点？）对估值影响，最优价值是否反向传播。
③估计的更新方式，非增长式（等着一起算）和增长式（来一个算一个）。
④epsilon关乎采样策略的探索性和最优性，
大则探索性强、最优性弱，小则探索性弱、最优性强，
⑤如果epsilon大到一定程度，可能会导致epsilon-greedy与最优greedy不一致。

(1) MC-Basic
二次循环，遍历所有(s, a)；某个策略下，每对采足够样，非增长式估计相应Q。
策略相应的，一套稳定Q值下，策略改进。
迭代。

(2) MC-Exploring-Starts
起始分布，覆盖(s, a)全集。
Pi下，充分利用每一个trajectory里的所有(s, a)对，访问，增长式估计相应Q。
每一个trajectory结束后，Q值未必稳定，都进行策略改进。
迭代。

(3) MC-epsilon-greedy
过程分布，覆盖(s, a)全集。
e-Pi下，充分利用每一个trajectory里的所有(s, a)对， 访问，增长式估计相应Q。
每一个trajectory结束后，Q值未必稳定，都进行策略改进，生成e-Pi。
迭代。

*stochastic approximation

理解:
以某形式的公式，为理论依据，进行实际采样与近似估计。

(1) Incremental-Estimation:

$$w_k = \frac{1}{k}\sum_{i=1}^{k} x_i \qquad\qquad w_{k-1} = \frac{1}{k-1}\sum_{i=1}^{k-1} x_i$$

$$w_k = \frac{1}{k}\left[(k-1)w_{k-1} + x_k\right] \quad = w_{k-1} + \frac{1}{k}\left[x_k - w_{k-1}\right]$$

(2) Robbins-Monro:

$g(w) = 0$ (g is unknown, w is input, 0 is output)

$g(w) = \nabla_w L(w) = 0$ (w is parametres)

$g(w) = L(w) - C = 0$

w* is the solution (Convergence Condition)

$$w_{k+1} = w_k + a_k\left[\tilde{g}\left(w_k, \eta_k\right) - 0\right]$$
$$= w_k + a_k\left(g(w_k) + \eta_k\right)$$
$$iteration: \quad \{w_k\} + \{\tilde{g}_k\} + \{a_k\}$$

(3) Optimazation:

$$\min_w J(w) = E\left[f(w, X)\right]$$
$$\Rightarrow\Rightarrow \qquad \nabla_w E\left[f(w, X)\right] = 0$$
$$\Rightarrow\Rightarrow \qquad Gradient: \quad InputSpace, \quad direction + magnitude$$

GD + (Mini)Batch GD + Stochastic GD:

$$w_{k+1} = w_k - \alpha_k \nabla_w E\left[f(w_k, X)\right] = w_k - \alpha_k E\left[\nabla_w f(w_k, X)\right]$$

$$w_{k+1} = w_k - \alpha_k \frac{1}{n}\sum_{i=1}^{n} \nabla_w f(w_k, x_i)$$

$$w_{k+1} = w_k - \alpha_k \nabla_w f(w_k, x_k)$$

ch5: Temporal Difference

理解:

Model-free. Dynamics with Transition.

①TD时序差分：在不同时刻，对同一个量估计，有差，利用差改进估计。

②没有模型p、只有数据t，进行估计:

MC利用整条trajectory，估计V、Q，离线/无偏/大方差;

TD利用片段transition，估计V、Q，在线/有偏/小方差。

③SARSA，用TD估计某个Pi的Q。

④Q-Learning，用TD直接估计Q*。（异轨，从数据中提取共性MDP-Q*信息）

⑤行为策略采集数据，利用数据计算TD-target（数据组织形式），

目标策略的估计值趋向TD-target，即TD-target代表着目标策略。

⑥on-policy: 用一个策略和环境交互，得到experience， 估计这个策略，改进这个策略。

再用改进的策略循环，交互、估计、改进，直至最优（这个系列的最优）。

off-policy: 一个策略和环境交互，得到experience，

另一个策略被估计、被改进。（目标策略不易采集数据，所以需要行为策略，异轨）

experience应当具有一些性质，能够架通两个策略，

行为策略能够采到，目标策略能够使用。

(1) TD-V: s-a-r-s

$$v_{t+1}(s_t) = v_t(s_t) + \alpha_t[[r_{t+1} + \gamma v_t(s_{t+1})] - v_t(s_t)]$$
$$v_{t+1}(s) = v_t(s) \qquad \forall s \neq s_t$$

(2) TD-Q:　　SA-R-SA

Policy Evaluation:

$$q_{t+1}(s_t, a_t) = q_t(s_t, a_t) + \alpha_t(s_t, a_t)[r_{t+1} + \gamma q_t(s_{t+1}, a_{t+1}) - q_t(s_t, a_t)]$$
$$q_{t+1}(s, a) = q_t(s, a) \qquad \forall (s, a) \neq (s_t, a_t)$$

Policy Improvement:
某个策略下的Q值可能还未估计稳定，
就可以进行策略提升。最终目标提升至Q*。

(3) TD-Q*:　　Q*-Learning　(s-a-r-s)

Value Improvement:

$$q_{t+1}(s_t, a_t) = q_t(s_t, a_t) + \alpha_t(s_t, a_t)[r_{t+1} + \gamma \max_a q_t(s_{t+1}, a) - q_t(s_t, a_t)]$$
$$q_{t+1}(s, a) = q_t(s, a) \qquad \forall (s, a) \neq (s_t, a_t)$$

*(DP+MC+TD)-Summary:

value	DP-model(p)	TD-data(t)
v	Policy-Evaluation(vBEs)	TD(0/n/...)
v*	Value-iteration(vBOEs)	-
q	Policy-Evaluation(qBEs)	TD(0)=SARSA
q*	Value-iteration(qBOEs)	Q*-Learning

ch6: Value Function Approximation

理解:
①函数拟合的优势：用更少的参数量（存储），估计，更多的状态量（泛化）；
原因在于，函数这种表达形式，存储了更本质的信息。
函数拟合的劣势：存在精度损失。
函数拟合的关键：最优的结构 + 最优的参数，提升拟合准确程度。
②状态分布(.)：平均分布U、稳态分布D（D + (pi+p) = D）。
优化时，SGD将不同分布吸收拉平了。
③某个真实分布中的一系列真值，形成一个超面；
经过各种采样，得到超面的部分观测真值；
建立一个模型并优化参数，用来拟合部分观测真值得到的超面。

(1) Objective Function:

$$J(w) = E_{S\sim(.)}[(v_\pi(S) - \tilde{v}(S,w))^2]$$

(2) Optimazation:

$$\begin{aligned} w_{k+1} &= w_k - \alpha_k \nabla_w J(w_k) \\ w_{t+1} &= w_t + \alpha_t(v_\pi(s_t) - \tilde{v}(s_t,w_t))\nabla_w \tilde{v}(s_t,w_t) \end{aligned}$$

(3) Algorithm:

$$\begin{aligned} w_{t+1} &= w_t + \alpha_t(g_t - \tilde{v}(s_t,w_t))\nabla_w \tilde{v}(s_t,w_t) && MC + VA \\ w_{t+1} &= w_t + \alpha_t[r_{t+1} + \gamma\tilde{v}(s_{t+1},w_t) - \tilde{v}(s_t,w_t)]\nabla_w \tilde{v}(s_t,w_t) && TD + VA \end{aligned}$$

(4) Approximator:

$$\begin{aligned} linear &= kx + b \\ nonlinear &= neural \;\; network \end{aligned}$$

(5) SARSA + VA: (SA-R-SA + q- + w)

Value Update(w):

$$w_{t+1} = w_t + \alpha_t[r_{t+1} + \gamma\tilde{q}(s_{t+1}, a_{t+1}, w_t) - \tilde{q}(s_t, a_t, w_t)]\nabla_w\tilde{q}(s_t, a_t, w_t)$$

Policy Improvement: epsilon-greedy

(6) Q*-Learning + VA: (S-A-R-S + q- + w)

Value Update(w):

$$w_{t+1} = w_t + \alpha_t[r_{t+1} + \gamma \max_a \tilde{q}(s_{t+1}, a, w_t) - \tilde{q}(s_t, a_t, w_t)]\nabla_w\tilde{q}(s_t, a_t, w_t)$$

Policy Improvement: (epsilon-)greedy

(7) Deep Q*-Learning: (Buffer(S-A-R-S) + NN(w)*2)

Value Update(w):

$$w_{t+1} = w_t + \alpha_t[r_{t+1} + \gamma \max_a \tilde{q}(s_{t+1}, a, w_T) - \tilde{q}(s_t, a_t, w_t)]\nabla_w\tilde{q}(s_t, a_t, w_t)$$

Policy Improvement: (epsilon-)greedy