

## ch1: Markov Decision Process (static concepts)

state(S) - policy(pi) - action(A) - model(p) - state(S')

reward(R') from transition

return(G) from trajectory

value(V+Q)

策略与价值:

①reward、return、value, 用来评估一个策略的好坏。

策略与价值一一对应。

②价值比较, 策略比较, 策略改进定理。

③强化学习的终极目标, 求取最优策略,

最优策略不唯一, 最优价值唯一。

最优动作价值, 意味着选取这个动作, 未来回报的期望最大。

④r线性变换, V+Q线性变换, 改变最优价值, 不改变greedy最优策略。

⑤迭代时, 最优策略可能已经稳定了, 但是对应的最优价值还没稳定。

⑥从终止状态反向迭代更新价值, 速度更快。但是哪里是终止状态? 上帝视角。

$$p(s', r | s, a) = \Pr \{S_t = s', R_t = r | S_{t-1} = s, A_{t-1} = a\}$$

$$\sum_{s' \in S} \sum_{r \in R} p(s', r | s, a) = 1$$

$$p(s' | s, a) = \sum_{r \in R} p(s', r | s, a)$$

$$r(s, a) = \sum_{s' \in S} \sum_{r \in R} (p(s', r | s, a) * r)$$

## ch2: Bellman Equations (static relations)

实质：描述状态值之间的静态关系（单项形式、矩阵形式）

求解：（矩阵求逆、数值迭代）—（policy-evaluation）

$$\begin{aligned}v_{\pi}(s) &= E_{\pi}[G_t \mid S_t = s] \\&= E_{\pi}[R_{t+1} + \gamma G_{t+1} \mid S_t = s] \\&= \sum_{a \in A} \pi(a \mid s) \sum_{s', r} p(s', r \mid s, a) * [r + \gamma E_{\pi}[G_{t+1} \mid S_{t+1} = s']] \\&= \sum_{a \in A} \pi(a \mid s) \sum_{s', r} p(s', r \mid s, a) * [r + \gamma v_{\pi}(s')] \\&= \sum_{a \in A} (\pi(a \mid s) * q_{\pi}(s, a))\end{aligned}$$

$$\begin{aligned}q_{\pi}(s, a) &= E_{\pi}[G_t \mid S_t = s, A_t = a] \\&= E_{\pi}[R_{t+1} + \gamma G_{t+1} \mid S_t = s, A_t = a] \\&= \sum_{s', r} p(s', r \mid s, a) * [r + \gamma E_{\pi}[G_{t+1} \mid S_{t+1} = s']] \\&= \sum_{s', r} p(s', r \mid s, a) * [r + \gamma v_{\pi}(s')] \\&= \sum_{s', r} p(s', r \mid s, a) * \left[ r + \gamma \sum_{a' \in A} (\pi(a' \mid s') * q_{\pi}(s', a')) \right]\end{aligned}$$

policy-comparison:

$$\pi' \geq \pi \quad \longleftrightarrow \quad v_{\pi'}(s) \geq v_{\pi}(s) \quad \forall s \in S$$

policy-improvement:

$$E_{\pi'} [q_{\pi}(s, \pi'(s))] \geq v_{\pi}(s) = E_{\pi} [q_{\pi}(s, \pi(s))] \quad \forall s \in S$$

Bellman Optimal Equations:

$$\begin{aligned} v_*(s) &= \max_{\pi} v_{\pi}(s) \\ &= \max_{\pi} (r_{\pi} + \gamma P_{\pi} v) \\ &= \max_{a \in A} q_{\pi^*}(s, a) \quad \forall s \in S \end{aligned}$$

Contraction Mapping Theorem (迭代收敛至唯一不动点)  
贝尔曼最优方程的收缩迭代过程，即是value iteration算法

## ch3: Dynamic Programming (dynamics with model p)

(1) Value Iteration:

$$v_{k+1} = \max_{\pi} (r_{\pi} + \gamma P_{\pi} v_k)$$

Policy Update:

$$\pi_{k+1} = \arg \max_{\pi} (r_{\pi} + \gamma P_{\pi} v_k)$$

Value Update:

$$v_{k+1} = r_{\pi_{k+1}} + \gamma P_{\pi_{k+1}} v_k$$

(2) Policy Iteration:

Policy Evaluation: (matrix solution vs. iteration solution)

$$v_{\pi_k} = r_{\pi_k} + \gamma P_{\pi_k} v_{\pi_k}$$

Policy Improvement:

$$\pi_{k+1} = \arg \max_{\pi} (r_{\pi} + \gamma P_{\pi} v_k)$$

(3) Turncated Iteration:

值迭代有限次数，介于1次与无穷次之间；值也未稳定，就进行策略改进

## ch4: Monte Carlo (model-free, dynamics with trajectory)

Sample:

$$v_{\pi}(s) = E_{\pi} [G_t \mid S_t = s]$$
$$q_{\pi}(s, a) = E_{\pi} [G_t \mid S_t = s, A_t = a]$$

理解:

- ①采样进行估计，基于概率论的大数定理。
- ②episode长度（探索半径是否覆盖终点？）对估值影响，最优价值是否反向传播。
- ③估计的更新方式，非增长式（等着一起算）和增长式（来一个算一个）。
- ④epsilon关乎采样策略的探索性和最优性，  
大则探索性强、最优性弱，小则探索性弱、最优性强，
- ⑤如果epsilon大到一定程度，可能会导致epsilon-greedy与最优greedy不一致。

### (1) MC-Basic

二次循环，遍历所有(s, a)；某个策略下，每对采足够样，非增长式估计相应Q。  
策略相应的，一套稳定Q值下，策略改进。  
迭代。

### (2) MC-Exploring-Starts

起始分布覆盖(s, a)全集。  
Pi下，充分利用每一个trajectory里的所有(s, a)对，访问，即增长式估计相应Q。  
每一个trajectory结束后，Q值未必稳定，都进行策略改进。  
迭代。

### (3) MC-epsilon-greedy

过程分布覆盖(s, a)全集。  
e-Pi下，充分利用每一个trajectory里的所有(s, a)对，访问，即增长式估计相应Q。  
每一个trajectory结束后，Q值未必稳定，都进行策略改进，生成e-Pi。  
迭代。

## \*stochastic approximation

(1) Incremental-Estimation:

$$\begin{aligned}w_k &= \frac{1}{k} \sum_{i=1}^k x_i & w_{k-1} &= \frac{1}{k-1} \sum_{i=1}^{k-1} x_i \\w_k &= \frac{1}{k} [(k-1)w_{k-1} + x_k] & &= w_{k-1} + \frac{1}{k} [x_k - w_{k-1}]\end{aligned}$$

(2) Robbins-Monro:

$$\begin{aligned}g(w) &= 0 && \text{(g is unknown, w is input, 0 is output)} \\g(w) &= \nabla_w L(w) = 0 && \text{(w is parameters)} \\g(w) &= L(w) - C = 0 \\w^* &\text{ is the solution (Convergence Condition)}\end{aligned}$$

$$\begin{aligned}w_{k+1} &= w_k + a_k [\tilde{g}(w_k, \eta_k) - 0] \\&= w_k + a_k (g(w_k) + \eta_k) \\iteration &: \{w_k\} + \{\tilde{g}_k\} + \{a_k\}\end{aligned}$$

(3) Optimazation:

$$\begin{aligned}\min_w J(w) &= E[f(w, X)] \\&\Rightarrow \Rightarrow \quad \nabla_w E[f(w, X)] = 0 \\&\Rightarrow \Rightarrow \quad \textit{Gradient} : \quad \textit{InputSpace}, \quad \textit{direction} + \textit{magnitude}\end{aligned}$$

GD + (Mini)Batch GD + Stochastic GD:

$$\begin{aligned}w_{k+1} &= w_k - \alpha_k \nabla_w E[f(w_k, X)] = w_k - \alpha_k E[\nabla_w f(w_k, X)] \\w_{k+1} &= w_k - \alpha_k \frac{1}{n} \sum_{i=1}^n \nabla_w f(w_k, x_i) \\w_{k+1} &= w_k - \alpha_k \nabla_w f(w_k, x_k)\end{aligned}$$

## ch5: Temporal Difference

(1) 基于数据 transition 的价值估计、策略改进: